

دانشگاه اصفهان

دانشکده مهندسی کامپیوتر

پروژه پایانی درس بازیابی اطلاعات

طراحی و پیاده‌سازی موتور جستجوی متنی (فاز اول)

استاد درس: دکتر زجاجی

دستیار آموزشی: بردیا جوادی

معین‌رضا باقری

سمیه حیدری

خرداد ۱۴۰۵

۱. مقدمه و هدف پروژه

هدف اصلی این پروژه، طراحی و پیاده‌سازی بخش اساسی و زیرساختی یک موتور جستجوی متنی بر پایه‌ی «مدل بازیابی بولی» (Boolean Retrieval Model) است. این سیستم با ایجاد ساختار داده‌ای بهینه به نام «ایندکس معکوس» (Inverted Index) بر روی مجموعه‌ای از داده‌های کرول‌شده از پلتفرم علمی گنج (ایرانداک)، امکان جستجوی سریع و دقیق متنی را در میان اسناد فراهم می‌آورد.

مجموعه داده‌های ورودی سیستم شامل آرایه‌ای از ۱۰۰ سند متنی علمی در قالب یک فایل JSON است که هر سند شامل فیلدهای ساختاریافته‌ای از جمله عنوان، چکیده، کلیدواژه‌ها، نویسنده، استاد راهنما، سال انتشار و مقطع تحصیلی است. در فاز اول پروژه، تمرکز بر روی فرآیندهای متن‌کاوی متناسب با زبان فارسی، ساخت بهینه‌ی لغت‌نامه و لیست‌های انتشار (Posting Lists)، و ارزیابی دقیق پرس‌وجوهای چندکلمه‌ای با عملگرهای منطقی AND و OR بدون در نظر گرفتن رتبه‌بندی آماری بوده است.

۲. معماری سیستم

معماری کلی سیستم از یک خط لوله (Pipeline) جریان داده تشکیل شده است که داده‌های خام ساختاریافته را دریافت کرده و پس از طی مراحل پیش‌پردازش متنی، لغت‌نامه‌ی مرکزی موتور جستجو را در حافظه مستقر می‌کند.

۲.۱ اجزای خط لوله پیش‌پردازش متنی با توجه به این‌که زبان متون اسناد فارسی است، استفاده از ابزارهای استاندارد پردازش زبان طبیعی نقشی کلیدی در افزایش نرخ بازیابی (Recall) دارد. در این پروژه از کتابخانه‌ی مجاز hazm استفاده شده و فرآیند پردازش متون اسناد و کلمات پرس‌وجو شامل مراحل زیر است:

- نرمال‌سازی (Normalization): یکسان‌سازی نویسه‌ها (تبدیل «ی» و «ک» عربی به فرمت استاندارد فارسی) و اصلاح فاصله‌گذاری‌ها و مدیریت نیم‌فاصله‌ها با ابزار Normalizer.
- توکن‌سازی (Tokenization): تجزیه‌ی رشته‌های متنی طولانی به کلمات مستقل با استفاده از تابع word_tokenize.
- حذف کلمات خنثی (Stopwords Removal): کلمات پر تکرار و فاقد ارزش اطلاعاتی (مانند: از، به، در، که، با) با ارجاع به لغت‌نامه‌ی استاندارد stopwords_list از حافظه حذف می‌شوند تا حجم ایندکس نهایی کاهش یابد.
- ریشه‌یابی (Lemmatization): کلمات به ریشه‌ی اصلی خود (اسم مفرد یا بن فعل) نگاشت می‌شوند. این کار به سیستم کمک می‌کند تا کلماتی مانند «می‌نویسد»، «نوشتند» و «نویسنده» را به یک ریشه‌ی واحد نگاشت کند و دقت تطبیق عبارات را به طرز چشمگیری افزایش دهد.

۳. روش ساخت ایندکس معکوس (Inverted Index)

پس از استخراج و تجمیع متون از فیلدهای کلیدی هر سند (شامل عنوان، چکیده و کلیدواژه‌ها)، توکن‌های نهایی به ساختار داده‌ی اصلی منتقل می‌شوند. ایندکس معکوس با بهره‌گیری از ساختار داده‌ی دیکشنری (Dictionary) پایتون پیاده‌سازی شده است که رفتاری مشابه Hash Map با پیچیدگی زمانی دسترسی O (1) دارد.

در این ساختار، هر کلید یک واژه‌ی متمایز و پیش‌پردازش‌شده در لغت‌نامه است و مقدار متناظر با آن، یک لیست صعودی و یکتا از شناسه‌های اسناد (Posting List) است که آن کلمه در آن‌ها تکرار شده است. شناسه سند (doc_id) برابر با اندیس موقعیتی سند در آرایه اصلی فایل JSON در نظر گرفته

شده است. برای جلوگیری از ثبت شناسه‌های تکراری برای یک واژه در یک سند مشخص، از ساختار داده‌ی set در زمان توکن‌سازی اسناد استفاده گردید. همچنین تعداد کل اسناد مجموعه به عنوان متغیر عمومی در کلاس ذخیره می‌شود.

۴. روش پردازش و ارزیابی Query

سیستم از مدل بازیابی بولی به طور کامل پشتیبانی می‌کند. کلمات ورودی پرس‌وجو دقیقاً از همان فیلترها و مراحل خط لوله‌ی پیش‌پردازش اسناد (نرمال‌سازی، حذف استاپ‌ورد و ریشه‌یابی) عبور می‌کنند تا با فرمت کلمات موجود در ایندکس همسان شوند. دو نوع اصلی پرس‌وجو به شرح زیر پردازش می‌شوند:

- پرس‌وجوی بولی چند کلمه‌ای AND: سیستم باید اسنادی را بازیابی کند که تمام کلمات موجود در پرس‌وجو را دارا باشند. پیاده‌سازی این بخش با فراخوانی Posting List متناظر با هر توکن به عنوان یک مجموعه (Set) و اعمال عملگر اشتراک منطقی (set.intersection) انجام می‌شود.
- پرس‌وجوی بولی چند کلمه‌ای OR: سیستم اسنادی را بازمی‌گرداند که حداقل یکی از کلمات پرس‌وجو در آن‌ها وجود داشته باشد. این بخش با ترکیب مجموعه‌ها از طریق عملگر اجتماع منطقی (set.union) پیاده‌سازی شده است.

۵. مکانیزم‌های پایداری و مدیریت حالت‌های خاص

مطابق با معیارهای ارزیابی سیستم، مکانیزم‌های دفاعی کد برای جلوگیری از بروز خطاهای زمان اجرا به شرح زیر طراحی شده‌اند:

۱.مدیریت کلمات ناموجود: در صورتی که کاربر کلمه‌ای را جستجو کند که در کل پیکره متنی اسناد وجود ندارد، سیستم با بهره‌گیری از متد get روی دیکشنری، به جای بروز خطای عدم وجود کلید (KeyError)، یک لیست خالی برگشت داده و آن را در محاسبات دخیل می‌کند.

۲.مدیریت کوئری‌های خالی یا شامل کلمات خنثی: اگر ورودی کاربر کاملاً خالی باشد یا فقط شامل کلماتی مثل «از» و «در» باشد که در فاز پیش‌پردازش حذف می‌شوند، شرط ابتدایی تابع جستجو یک لیست خالی را بدون کرش کردن برنامه بازمی‌گرداند.

۶. چالش‌های زبان فارسی و فرآیند توسعه

- تنوع ساختاری نویسه‌ها: تفاوت در کدهای اسکی نویسه‌های کاف و یای فارسی و عربی منجر به عدم تطابق در جستجو می‌شد که با طراحی نرمالایزر یکپارچه حل شد.
- حذف افعال و پسوندهای اشتقاقی: وجود نشانه‌های جمع و زمان‌های مختلف افعال نرخ پوشش کلمات را کاهش می‌داد. پیاده‌سازی ماژول ریشه‌یاب (Lemmatizer) و تجزیه فرم‌های ساختاری افعال این مشکل را برطرف کرد .
- بهینه‌سازی سرعت عملیات مجموعه‌ها :به جای استفاده از حلقه‌های تو در تو با پیچیدگی زمانی بالا مانند $O(n^2)$ ، با تبدیل لیست‌های موقت به ساختار داده‌ی Set در پایتون، سرعت پاسخ‌گویی به پرس‌وجوها به دلیل استفاده از جداول هش (Hash Tables) به شدت افزایش یافت.

۷. نتایج ارزیابی و تست‌کیس‌های نمونه

سیستم طراحی شده با موفقیت بر روی فایل داده‌های واقعی اجرا گردید. خلاصه‌ای از نتایج ارزیابی و صحت‌سنجی خروجی‌ها در جدول زیر گزارش شده است:

	عبارت جستجو شده (Query)	نوع جستجو	تعداد اسناد یافت‌شده	وضعیت خطای سیستم
۱	مسئولیت مدنی	AND	۴ سند	موفق (بدون خطا)
۲	پزشکی درمان	OR	۹ سند	موفق (بدون خطا)
۳	واژه‌عجیب‌تست‌نشده	AND	۰ سند	موفق (کنترل کلمه ناموجود)
۴	از و با (فقط کلمات خنثی)	AND	۰ سند	موفق (کنترل کوئری خالی)

نتایج فوق نشان می‌دهد که موتور جستجو با پایداری کامل و انطباق دقیق با منطق بولی بازیابی اطلاعات، تمامی تست‌کیس‌های درخواستی را با موفقیت پاس کرده است.

```
Loading data and building index...
Indexing Documents: 100%|██████████| 100/100 [00:00<00:00, 207.45it/s]

Index built successfully! Total documents indexed: 100
Total unique tokens in vocabulary: 3000


================================================

>>> Test 1: AND Query ('مسئولیت مدنی')
Processed Query Tokens: ['مسئولیت', 'مدنی']
--- Found 4 documents ---
Doc ID: 6 | Title: مطالعه تطبیقی مسئولیت مدنی ناشی از استفاده از هوش مصنوعی در امور پزشکی در حقوق ایران و انگلیس
Doc ID: 29 | Title: مسئولیت مدنی ناشی از هوش مصنوعی
Doc ID: 52 | Title: مسئولیت مدنی ناشی از هوش مصنوعی
Doc ID: 77 | Title: امکان سنجی مسئولیت مدنی هوش مصنوعی در حقوق ایران و اتحادیه اروپا
----------------------------------------

>>> Test 2: OR Query ('پزشکی درمان')
Processed Query Tokens: ['پزشکی', 'درمان']
--- Found 9 documents ---
Doc ID: 3 | Title: ارزیابی عوامل موثر بر ایجاد اعتماد مشتری به هوش مصنوعی انسان نمای پزشکی در سامانه های سلامت
Doc ID: 6 | Title: مطالعه تطبیقی مسئولیت مدنی ناشی از استفاده از هوش مصنوعی در امور پزشکی در حقوق ایران و انگلیس
Doc ID: 15 | Title: مدیریت داده‌های مراقبت بهداشتی و درمان بیماری عصبی با رویکرد ماشین ترکیبی در هوش مصنوعی
Doc ID: 31 | Title: پیش بینی بیماری‌ها با استفاده از هوش مصنوعی
Doc ID: 33 | Title: بررسی ارتباط هوش مصنوعی با حق بر سلامت
Doc ID: 37 | Title: پیش بینی بیماری ها با استفاده از هوش مصنوعی
Doc ID: 67 | Title: تحلیل جرم شناختی زمینه های جرم زایی هوش مصنوعی
```

```
>>> Test 2: OR Query ('پزشکی درمان')
Processed Query Tokens: ['پزشکی', 'درمان']
--- Found 9 documents ---
Doc ID: 3 | Title: ارزیابی عوامل موثر بر ایجاد اعتماد مشتری به هوش مصنوعی انسان نمای پزشکی در سامانه های سلامت
Doc ID: 6 | Title: مطالعه تطبیقی مسئولیت مدنی ناشی از استفاده از هوش مصنوعی در امور پزشکی در حقوق ایران و انگلیس
Doc ID: 15 | Title: مدیریت داده‌های مراقبت بهداشتی و درمان بیماری عصبی با رویکرد ماشین ترکیبی در هوش مصنوعی
Doc ID: 31 | Title: پیش بینی بیماری‌ها با استفاده از هوش مصنوعی
Doc ID: 33 | Title: بررسی ارتباط هوش مصنوعی با حق بر سلامت
Doc ID: 37 | Title: پیش بینی بیماری ها با استفاده از هوش مصنوعی
Doc ID: 67 | Title: تحلیل جرم شناختی زمینه های جرم زایی هوش مصنوعی
Doc ID: 81 | Title: واکاوی عوامل مؤثر بر پذیرش و به کارگیری هوش مصنوعی در میان اعضای هیات علمی دانشگاههای ایران
Doc ID: 84 | Title: میزان آشنایی و استفاده از هوش مصنوعی در بین دانشجویان
----------------------------------------

>>> Test 3: Non-existent Word
No documents found.

>>> Test 4: Empty Query / Only Stopwords ('از و با')
No documents found.

Process finished with exit code 0
```